

CASO DE ESTUDIO:

Predicción del crecimiento de las exportaciones de productos en el Top 5 histórico a Estados Unidos utilizando Machine Learning

Juan José Triviño Zambrano

 Facultad de Ingeniería, Maestría en Sistemas de Información mención Data Science
 jjtrivino@puce.edu.ec

Resumen

El presente estudio aborda la predicción del crecimiento o decrecimiento de las exportaciones del Top 5 histórico de productos más exportados a Estados Unidos a partir de una base de datos proporcionada por el Ministerio de Producción, Comercio Exterior, Inversiones y Pesca (MPCEIP) desde el año 2001. Se realiza un análisis exploratorio de la base de datos con el objetivo de comprender las características de las exportaciones y sus cambios a lo largo de los años. Utilizando técnicas de Machine Learning, se desarrolla un modelo predictivo capaz de estimar el volumen de exportaciones en toneladas para el siguiente año. Los resultados obtenidos podrán contribuir a una mejor toma de decisiones en relación a la producción, inversión y estrategias comerciales por parte de los actores involucrados en el comercio exterior.

Palabras claves

exportaciones — machine learning — prophet

Índice

1	Introducción	1
2	Objetivos	2
2.1	Objetivo general	2
2.2	Objetivos específicos	2
3	Alcance	2
4	Marco metodológico	2
4.1	Recolección de datos	2
4.2	Preparación de datos	2
4.3	Selección de un modelo	2
4.4	Entrenamiento	2
4.5	Evaluación	3
4.6	Afinamiento de hiperparámetros	3
4.7	Predicción	3
5	Marco teórico	3
6	Discusión de resultados	4
7	Conclusiones	5
8	Recomendaciones	5
	Referencias	5

1. Introducción

El comercio internacional juega un papel fundamental en la economía de los países, siendo las exportaciones un factor clave en el desarrollo y crecimiento de las naciones. En este contexto, la capacidad de predecir el comportamiento de las exportaciones resulta esencial para la formulación de políticas y la toma de decisiones en el ámbito empresarial y gubernamental. Ecuador, al igual que otros países en desarrollo, enfrenta el desafío de diversificar y expandir sus exportaciones para fortalecer su economía y mejorar su posición en el mercado global.

La relación comercial entre Ecuador y Estados Unidos es de particular importancia, ya que este último representa uno de los principales destinos de las exportaciones ecuatorianas. El Ministerio de Producción, Comercio Exterior, Inversiones y Pesca (MPCEIP) posee una base de datos que contiene información detallada sobre las exportaciones realizadas a Estados Unidos desde el año 2001. El gobierno ecuatoriano ha solicitado la elaboración de predicciones sobre el crecimiento o decrecimiento de las exportaciones del Top 5 histórico de productos más exportados para el siguiente año, en términos de cantidad exportada (en toneladas).

El presente estudio aborda esta problemática mediante el uso de técnicas de Machine Learning para analizar los datos históricos y desarrollar un modelo predictivo que permita estimar el volumen de exportaciones del Top 5 de productos en el futuro próximo. Este enfoque busca brindar información

valiosa para la toma de decisiones de las autoridades y los actores involucrados en el comercio exterior, permitiendo la identificación de oportunidades y desafíos en el mercado internacional y la formulación de estrategias adecuadas para enfrentarlos.

2. Objetivos

2.1 Objetivo general

Desarrollar un modelo predictivo basado en Machine Learning para estimar el crecimiento o decrecimiento del volumen de exportaciones del Top 5 histórico de productos más exportados desde Ecuador a Estados Unidos en el siguiente año.

2.2 Objetivos específicos

- Realizar un análisis exploratorio de la base de datos proporcionada por el MPCEIP para comprender las características de las exportaciones y sus cambios a lo largo de los años, identificando patrones y tendencias relevantes en el Top 5 histórico de productos más exportados.
- Preprocesar y preparar los datos para su uso en el desarrollo del modelo predictivo, llevando a cabo tareas de limpieza, transformación y selección de variables relevantes.
- Crear un modelo con técnicas de Machine Learning que permita predecir el crecimiento o decrecimiento del volumen en toneladas de las exportaciones del Top 5 histórico de productos exportados a Estados Unidos.
- Definir un método o técnica conveniente que permita realizar las predicciones con los datos y variables provistos.

3. Alcance

El presente estudio se enfoca en analizar y predecir el crecimiento o decrecimiento del volumen de exportaciones del Top 5 histórico de productos más exportados desde Ecuador a Estados Unidos, utilizando los datos proporcionados por el Ministerio de Producción, Comercio Exterior, Inversiones y Pesca (MPCEIP) desde el año 2001 hasta la fecha de corte de conocimiento en 2021. El alcance del estudio abarca los siguientes aspectos:

1. La investigación se limita al análisis de las exportaciones de los cinco productos principales en términos de cantidad exportada (en toneladas), sin considerar otros productos o variables económicas adicionales que puedan influir en el comercio exterior.
2. Se analizarán exclusivamente las exportaciones realizadas desde Ecuador hacia Estados Unidos, sin incluir otros destinos o relaciones comerciales internacionales.

3. El modelo predictivo desarrollado tiene como objetivo estimar el volumen de exportaciones del Top 5 histórico de productos para el siguiente año, no abordando predicciones a largo plazo o tendencias futuras más allá de ese periodo.
4. El estudio no pretende ofrecer un análisis exhaustivo de las causas o factores que influyen en el crecimiento o decrecimiento de las exportaciones, sino que se centra en la aplicación de técnicas de Machine Learning para predecir el comportamiento de las exportaciones en base a los datos históricos disponibles.
5. Las conclusiones y recomendaciones derivadas del estudio estarán enfocadas en la toma de decisiones relacionadas con la producción, inversión y estrategias comerciales en el contexto del comercio exterior entre Ecuador y Estados Unidos, sin entrar en detalles específicos de políticas gubernamentales o acciones a nivel empresarial.

4. Marco metodológico

El presente estudio seguirá un enfoque estructurado basado en los pasos del aprendizaje automático, que se integran con las fases CRISP-DM, para desarrollar un modelo predictivo del crecimiento o decrecimiento del volumen de exportaciones del Top 5 histórico de productos más exportados desde Ecuador a Estados Unidos. A continuación, se detallan las etapas del proceso las cuales se integran y las herramientas que se utilizarán en cada paso:

4.1 Recolección de datos

Los datos históricos de exportación serán obtenidos de la base de datos proporcionada por el Ministerio de Producción, Comercio Exterior, Inversiones y Pesca (MPCEIP), disponible en formato CSV [en el enlace mencionado](#).

4.2 Preparación de datos

Se utilizará Python como lenguaje de programación, junto con la biblioteca pandas para llevar a cabo tareas de limpieza, transformación y selección de variables relevantes. Se identificarán y tratarán los datos faltantes, se convertirán las variables categóricas en numéricas si es necesario y se normalizarán o estandarizarán las variables según corresponda.

4.3 Selección de un modelo

Dado que el problema de investigación implica la predicción de series de tiempo, se seleccionará el modelo Facebook Prophet para su implementación. Este modelo ha demostrado ser efectivo y fácil de utilizar para predecir series temporales en diversos dominios.

4.4 Entrenamiento

Se dividirá el conjunto de datos en datos de entrenamiento y prueba, utilizando una proporción adecuada. Luego, se

entrenará el modelo Facebook Prophet utilizando el conjunto de datos de entrenamiento.

4.5 Evaluación

Se evaluará el rendimiento del modelo utilizando el conjunto de datos de prueba y la biblioteca scikit-learn. Se calcularán métricas como el error cuadrático medio (MSE), el error absoluto medio (MAE) y el coeficiente de determinación (R^2) para medir la precisión del modelo.

4.6 Afinamiento de hiperparámetros

Si es necesario, se llevará a cabo una búsqueda en la cuadrícula (grid search) o una búsqueda aleatoria (random search) para optimizar los hiperparámetros del modelo y mejorar su rendimiento.

4.7 Predicción

Una vez que se haya logrado un rendimiento satisfactorio, se utilizará el modelo para realizar predicciones sobre el crecimiento o decrecimiento del volumen de exportaciones del Top 5 histórico de productos para el siguiente año. Estas predicciones servirán como base para las conclusiones y recomendaciones del estudio.

Este enfoque metodológico permite abordar de manera sistemática y rigurosa el problema de investigación, garantizando la calidad y confiabilidad de los resultados obtenidos.

5. Marco teórico

Prophet es un marco de código abierto de Facebook utilizado para enmarcar y predecir series temporales. Se centra en un modelo aditivo en el cual las tendencias no lineales se ajustan con estacionalidades diarias, semanales y anuales, además de efectos adicionales de días festivos. Prophet es eficiente en el manejo de datos faltantes y cambios en las tendencias, y generalmente maneja bien los valores atípicos. También permite acumular variables exógenas en el modelo.

Prophet utiliza un modelo de serie temporal descomponible:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t$$

Donde:

- **$y(t)$** es la predicción en el tiempo t .
- **$g(t)$** representa la función de tendencia que modela cambios no lineales a lo largo del tiempo.
- **$s(t)$** es la función de estacionalidad que captura patrones periódicos (diarios, semanales y anuales) en los datos.
- **$h(t)$** es la función que modela los efectos de los días festivos o eventos especiales.
- ε_t es el término de error en el tiempo t .

Este modelo no tiene en cuenta la dependencia temporal de los datos, a diferencia del modelo ARIMA(p, d, q), donde los valores futuros dependen de los valores pasados. Por lo tanto, este proceso se acerca más a ajustar una curva a los datos que a encontrar el proceso subyacente. Aunque se pierde cierta información predictiva al usar este método, tiene la ventaja de ser muy flexible, ya que puede adaptarse a múltiples periodos estacionales y tendencias cambiantes. Además, es resistente a valores atípicos y datos faltantes, lo cual es una clara ventaja en un contexto empresarial. (Peixeiro 2021)

La inclusión de múltiples periodos estacionales se motivó por la observación de que el comportamiento humano produce series de tiempo estacionales de múltiples periodos. Por ejemplo, la semana laboral de cinco días puede producir un patrón que se repite cada semana, mientras que las vacaciones escolares pueden producir un patrón que se repite cada año. Por lo tanto, para tener en cuenta múltiples periodos estacionales, Prophet utiliza la serie de Fourier para modelar efectos periódicos múltiples. Específicamente, la componente estacional $s(t)$ se expresa en la siguiente ecuación:

$$s(t) = \sum_{n=1}^N \left(a_n \cos\left(\frac{2\pi nt}{P}\right) + ab_n \sin\left(\frac{2\pi nt}{P}\right) \right)$$

Donde P es el período consistente que anticipamos que tendrá la serie de tiempo. Ajustar la estacionalidad requiere calcular los parámetros desarrollando una matriz de vectores de estacionalidad para cada uno y cada valor P en los datos históricos y futuros.

N es simplemente el número de parámetros que deseamos utilizar para estimar el componente estacional. Esto tiene el beneficio adicional de que la temporada la sensibilidad del componente se puede ajustar dependiendo de cuántos parámetros N son estimada para modelar la estacionalidad. Por defecto, Prophet usa 10 términos para modelar la estacionalidad anual y 3 términos para modelar la estacionalidad semanal.

La flexibilidad de Prophet puede convertirlo en una opción atractiva para realizar pronósticos rápidos y precisos. Sin embargo, no debe considerarse una solución única para todos. La documentación mismo especifica que Prophet funciona mejor con series de tiempo que tienen una fuerte efecto estacional con varias temporadas de datos históricos. Por lo tanto, puede haber situaciones donde Prophet no es la opción ideal, pero está bien, ya que tienes una variedad de modelos estadísticos y de aprendizaje profundo en su cinturón de herramientas para producir pronósticos. (B. V. Vishwas 2020) Además, el paquete de Facebook aporta ventajas, como:

- Capacidad para manejar conjuntos de datos en varios niveles de granularidad, como datos minuto a minuto o datos por hora, además de datos diarios
- Tendencias que indican un crecimiento no lineal, como alcanzar un punto de saturación (Nielsen 2019)

6. Discusión de resultados

Para predecir las cantidades exportadas hubo que recortar el dataset en un subconjunto de años en donde exista una tendencia mas clara de tal manera que al ajustar la escala temporal capture tendencia y estacionalidad de mejor forma. Si una serie de tiempo no tiene una tendencia o estacionalidad clara, puede parecer errática porque no hay un patrón subyacente que se pueda identificar fácilmente.

Para esta serie de tiempo se recortaron las observaciones desde el año 2015.




Figura 1. Predicción de Petróleo Crudo

Para esta serie de tiempo se recortaron las observaciones desde el año 2001.




Figura 2. Predicción de Banano

Para esta serie de tiempo se recortaron las observaciones desde el año 2020.




Figura 3. Predicción de Derivados de Petróleo

Para esta serie de tiempo se recortaron las observaciones desde el año 2001.




Figura 4. Predicción de Plátano

Para esta serie de tiempo se recortaron las observaciones desde el año 2019.




Figura 5. Predicción de Camarones

Los resultados de las predicciones se observan en el cuadro resumen detallado mensualmente, en donde también se pueden observar algunas métricas comunes que nos dan cuenta del nivel de ajuste y la calidad del modelo.

Tabla 1. Predicciones del siguiente año por meses

Fecha	Petróleo	Banano	Derivados	Plátano	Camarones
2021-10	471.384	44.655	133.637	9.918	13.712
2021-11	363.518	49.030	141.279	9.870	13.332
2021-12	381.558	65.733	148.675	11.331	14.149
2022-01	400.948	73.566	156.318	12.010	16.644
2022-02	289.094	68.336	163.960	11.614	17.732
2022-03	367.134	67.644	170.863	13.337	17.784
2022-04	211.866	63.931	178.506	12.060	17.751
2022-05	182.334	63.769	185.902	11.794	21.453
2022-06	228.013	63.843	193.544	10.980	19.916
2022-07	447.887	66.778	200.940	10.600	20.558
2022-08	386.877	52.860	208.583	10.022	20.481
2022-09	292.353	43.241	216.225	9.731	18.344
TOTAL	4.022.968	723.388	2.098.430	133.267	211.856

Tabla 2. Métricas de evaluación del modelo

	Petróleo	Banano	Derivados	Plátano	Camarones
MAE	240.569	10.145	46.633	1.293	2.324
MSE	8,94E+10	1,41E+08	3,12E+09	3,09E+06	8,17E+06
RMSE	298.950	11.863	55.887	1.757	2.858
R²	-1,37	0,39	0,38	0,26	0,32

7. Conclusiones

Es el caso de una tendencia errática, en estos productos, es posible que se deba investigar más a fondo para determinar si hay factores externos que están influyendo en la tendencia y que no se han tenido en cuenta en el modelo.

Se seleccionó un subconjunto de años del dataset para capturar la tendencia y estacionalidad de manera más clara lo cual puede ser útil en ciertas situaciones, como por ejemplo:

- **Cambio estructural:** Si ha habido un cambio estructural en la serie de tiempo que ha provocado cambios significativos en la tendencia y la estacionalidad, puede ser útil centrarse en un período más reciente que refleje mejor la situación actual.
- **Datos poco confiables o ruidosos:** Si los datos en algunos períodos son de baja calidad o contienen mucho ruido, puede ser beneficioso excluir esos períodos para mejorar la calidad de los datos y la precisión de las predicciones.
- **Cambio en las políticas o regulaciones:** Si hubo cambios significativos en las políticas o regulaciones que afectan la serie de tiempo, puede ser útil centrarse en el período posterior a estos cambios para capturar la tendencia y estacionalidad de manera más precisa.

8. Recomendaciones

Si bien algunos modelos de series de tiempo pueden manejar la ausencia de tendencia o tendencias erráticas, es importante tener en cuenta que la precisión de las predicciones puede verse afectada en tales casos, ya que los modelos pueden tener dificultades para capturar la variabilidad en los datos. Es crucial evaluar la calidad del ajuste del modelo y validar sus predicciones con datos históricos antes de utilizarlo para hacer pronósticos futuros.

Para abordar una serie de tiempo errática, es posible que se tenga que investigar las causas subyacentes de la variabilidad y si es posible, tratar de incorporar información adicional en el análisis para mejorar la precisión de las predicciones. También se podría considerar técnicas de suavizado, como promedios móviles o técnicas de descomposición, para reducir la variabilidad y resaltar las tendencias y estacionalidades subyacentes. En algunos casos, también puede ser útil utilizar modelos de series de tiempo más avanzados, como ARIMA, modelos de estado espacio o modelos de redes neuronales multiarados, que pueden manejar mejor la variabilidad y capturar patrones más complejos en los datos.

Referencias

- B. V. Vishwas, Ashish Patel (2020). *Hands-on Time Series Analysis With Python: From Basics To Bleeding Edge Techniques*. 1st Edition. Apress. ISBN: 1484259912,9781484259917,9781484259918. URL: <http://gen.lib.rus.ec/book/index.php?md5=EBDDA4417E23AC3A52333B8A9C4EBF56> (vid. pág. 3).
- Nielsen, A. (2019). *Practical Time Series Analysis: Prediction with Statistics and Machine Learning*. O'Reilly Media. ISBN: 9781492041627. URL: <https://books.google.com.ec/books?id=odCwDwAAQBAJ> (vid. pág. 3).
- Peixeiro, Marco (2021). *Time Series Forecasting in Python*. MEAP Edition. Manning Publications. URL: <http://gen.lib.rus.ec/book/index.php?md5=6237F9B0B0837A43ACB036A8C91C842E> (vid. pág. 3).